

DoRA and LoRA

Implement from Beginning

3ChuBeDan

Vietnam National University - University of Engineering and Technology
Institute for Artificial Intelligence

Ngày 19 tháng 6 năm 2026

Dàn ý trình bày

- 1 LoRA - Parameter-Efficient Fine-Tuning - Tinh chỉnh tham số hiệu quả
- 2 DoRA: : Weight-Decomposed Low-Rank Adaptation
- 3 Tài liệu tham khảo


Bài toán ESG và yêu cầu đối với mô hình

Bài toán

- Phân loại **đa nhãn** các đoạn văn báo cáo thường niên tiếng Việt.
- Gán đồng thời các khía cạnh: **E** (môi trường), **S** (xã hội), **G** (quản trị).
- Dữ liệu có nhãn yếu, số lượng hạn chế (~2.4k mẫu), mất cân bằng nặng.

Yêu cầu mô hình

- **Hiệu quả tham số** – tránh full fine-tuning PhoBERT (135M tham số).
- **Chống overfitting** trên tập nhỏ, nhãn yếu.
- **Tiết kiệm VRAM** để huấn luyện được trên GPU hạn chế.
- **Kiểm soát được quá trình học** (khởi tạo, gradient).



Mục lục phần

1 LoRA - Parameter-Efficient Fine-Tuning - Tinh chỉnh tham số hiệu quả

- LoRA - Parameter-Efficient Fine-Tuning (PEFT)
- Nút thắt hình học của LoRA

2 DoRA: : Weight-Decomposed Low-Rank Adaptation

3 Tài liệu tham khảo

Mục lục phần

- 1 **LoRA - Parameter-Efficient Fine-Tuning - Tinh chỉnh tham số hiệu quả**
 - **LoRA - Parameter-Efficient Fine-Tuning (PEFT)**
 - Nút thắt hình học của LoRA
- 2 DoRA: : Weight-Decomposed Low-Rank Adaptation
- 3 Tài liệu tham khảo

LoRA - Parameter-Efficient Fine-Tuning - Tinh chỉnh tham số hiệu quả (PEFT)

- Dựa trên giả thuyết cho rằng các thay đổi được tạo ra trong quá trình tinh chỉnh có 'hạng nội tại' (intrinsic rank) thấp, LoRA (Hu et al., 2022) đề xuất sử dụng tích của hai ma trận hạng thấp để cập nhật trọng số tiền huấn luyện. LoRA giải quyết chi phí của FFT bằng cách đóng băng ma trận tiền huấn luyện $W_0 \in \mathbb{R}^{d \times k}$ và chỉ học cách hiệu chỉnh phần thích nghi ΔW .

- Trọng số sau thích nghi được viết:

$$W' = W_0 + \Delta W = W_0 + BA.$$

- Trong đó:

$$B \in \mathbb{R}^{d \times r}, \quad A \in \mathbb{R}^{r \times k}, \quad r \ll \min(d, k).$$

- Thay vì học $d \times k$ tham số, LoRA chỉ học:

$$\#\text{params}_{\text{LoRA}} = r \times (d + k) \ll d \times k.$$

- Phương pháp này hiệu quả nhất khi cập nhật theo tác vụ nằm gần một không gian con thấp chiều của không gian tham số đầy đủ.
- Vì ma trận W_0 được giữ cố định, tri thức tiền huấn luyện được bảo toàn trực tiếp hơn và kích thước checkpoint nhỏ hơn nhiều.

Mục lục phần

- 1 LoRA - Parameter-Efficient Fine-Tuning - Tinh chỉnh tham số hiệu quả**
 - LoRA - Parameter-Efficient Fine-Tuning (PEFT)
 - **Nút thắt hình học của LoRA**
- 2 DoRA: : Weight-Decomposed Low-Rank Adaptation
- 3 Tài liệu tham khảo

Nút thắt hình học của LoRA

- Mặc dù LoRA hiệu quả về mặt tham số, nhưng độ chính xác của nó không tương đương với tinh chỉnh toàn phần (full fine-tuning).
- Thành phần hiệu chỉnh cộng bị giới hạn trong không gian con hạng thấp:

$$W' = W_0 + BA, \quad \Delta W \in \mathcal{S}_r, \quad \dim(\mathcal{S}_r) \ll d \times k$$

- Để dễ hình dung, ta có thể coi bộ tối ưu (optimizer) chỉ khám phá một **đa tạp con thấp chiều** (low-dimensional submanifold) bên trong không gian tham số đầy đủ:

$$\Delta W = \{BA | B \in \mathbb{R}^{d \times r}, A \in \mathbb{R}^{r \times k}\}$$

- Trong hình học của LoRA, các thay đổi về độ lớn và hướng của véc-tơ trọng số bị 'khóa' chặt vào nhau bên trong một đa tạp con thấp chiều. Do đa tạp này có số chiều cực thấp, bộ tối ưu không thể di chuyển độc lập theo một hướng để thay đổi độ lớn mà không làm lệch hướng khiến thay đổi cấu trúc đặc trưng. Điều này tạo ra một sự ràng buộc hình học khắt khe, khiến mô hình khó lòng đạt được cấu hình trọng số tối ưu như trong không gian Euclid tự do của việc tinh chỉnh toàn phần (FFT).
- Sự sai lệch này trở nên trầm trọng khi hạng r nhỏ và tác vụ yêu cầu những thay đổi phức tạp trong hình học biểu diễn.

Mục lục phần

- 1 LoRA - Parameter-Efficient Fine-Tuning - Tinh chỉnh tham số hiệu quả
- 2 **DoRA: : Weight-Decomposed Low-Rank Adaptation**
 - Nền tảng toán học - Weight Normalization
 - Kiến trúc toán học của DoRA
 - Phân tích Gradient của DoRA
 - Đột phá hình học - Phép chiếu trực giao
 - Phân tích Động học: Tương quan nghịch giữa Hướng và Độ lớn
 - Tối ưu hóa bộ nhớ: Cơ chế Detached Gradient
- 3 Tài liệu tham khảo

Mục lục phần

- 1 LoRA - Parameter-Efficient Fine-Tuning - Tinh chỉnh tham số hiệu quả
- 2 **DoRA: : Weight-Decomposed Low-Rank Adaptation**
 - **Nền tảng toán học - Weight Normalization**
 - Kiến trúc toán học của DoRA
 - Phân tích Gradient của DoRA
 - Đột phá hình học - Phép chiếu trực giao
 - Phân tích Động học: Tương quan nghịch giữa Hướng và Độ lớn
 - Tối ưu hóa bộ nhớ: Cơ chế Detached Gradient
- 3 Tài liệu tham khảo

Nền tảng toán học - Weight Normalization

- Lấy ý tưởng từ Weight Normalization (Salimans & Kingma, 2016), DoRA đi theo ý tưởng tách biệt độ lớn của vector trọng số khỏi hướng của nó.
- Trong Weight Normalization, mỗi cột j của ma trận trọng số được phân rã thành:

$$\mathbf{w}_j = m_j \frac{\mathbf{v}_j}{\|\mathbf{v}_j\|_2}.$$

- Trong đó: m_j là đại lượng vô hướng điều khiển độ lớn, và $\mathbf{v}_j / \|\mathbf{v}_j\|_2$ là vector đơn vị dùng để xác định hướng. ($\|\cdot\|_2$ là chuẩn L^2 - Euclidean norm).
- Cách tiếp cận này thay đổi **cách cập nhật hình học của quá trình tối ưu**: độ lớn thay đổi dọc theo bán kính, trong khi hướng di chuyển trên mặt cầu đơn vị.
- Sự phân rã này giúp tách rời hai vai trò khác nhau của trọng số vốn bị **ràng buộc chặt chẽ** trong cách tham số hóa của LoRA, cho phép mô hình học được các quỹ đạo tối ưu hóa linh hoạt hơn.
- **Trực giác**: Việc cập nhật độ lớn và hướng bằng hai cơ chế riêng biệt giúp mô hình thích nghi hiệu quả hơn với dữ liệu mới.

Mục lục phần

- 1 LoRA - Parameter-Efficient Fine-Tuning - Tinh chỉnh tham số hiệu quả
- 2 **DoRA: : Weight-Decomposed Low-Rank Adaptation**
 - Nền tảng toán học - Weight Normalization
 - **Kiến trúc toán học của DoRA**
 - Phân tích Gradient của DoRA
 - Đột phá hình học - Phép chiếu trực giao
 - Phân tích Động học: Tương quan nghịch giữa Hướng và Độ lớn
 - Tối ưu hóa bộ nhớ: Cơ chế Detached Gradient
- 3 Tài liệu tham khảo

Kiến trúc toán học của DoRA

- Bảo toàn tri thức tiền huấn luyện: DoRA đảm bảo điểm khởi đầu nhất quán với mô hình gốc bằng cách thiết lập:

$$V = W_0, \quad m = \|W_0\|_c,$$

trong đó, $\|\cdot\|_c$ là chuẩn Euclid (L^2 norm) tính toán độc lập trên từng cột của ma trận trọng số (column-wise norm).

- Tái tham số hóa thành phần hướng: Nhánh thích nghi theo hướng (directional component) kế thừa cấu trúc của LoRA để cập nhật ma trận V một cách hiệu quả về tham số. DoRA, khi đó, được thiết lập theo công thức của phân rã trọng số, $W = m \frac{V}{\|V\|_c} = \|W\|_c \frac{W}{\|W\|_c}$ như sau:

$$W' = m \frac{V + \Delta V}{\|V + \Delta V\|_c} = m \frac{W_0 + BA}{\|W_0 + BA\|_c}.$$

Trong đó m, B, A là các tham số có thể huấn luyện (trainable parameters).

Đặc điểm hình học của DoRA

$$W' = m \frac{V + \Delta V}{\|V + \Delta V\|_c} = m \frac{W_0 + BA}{\|W_0 + BA\|_c}$$

- Loại bỏ sự ràng buộc giữa hướng và độ lớn: Trong cấu trúc này, hạng tử hạng thấp (BA) tập trung chuyên biệt vào việc tinh chỉnh **hướng** (direction), trong khi vector m đảm nhận vai trò điều chỉnh **độ lớn** (magnitude) một cách độc lập.
- Tính ổn định tại thời điểm khởi tạo: Nhờ thiết kế chuẩn hóa, tại bước $t = 0$, mô hình DoRA khôi phục chính xác trạng thái của mô hình W_0 .
- Mở rộng năng lực biểu đạt: Thiết kế này không chỉ duy trì tính hiệu quả của PEFT (Parameter-Efficient Fine-Tuning) mà còn giải phóng mô hình khỏi các ràng buộc hình học của LoRA chuẩn, cho phép quỹ đạo tối ưu hóa tiến gần hơn với tinh chỉnh toàn phần (Full Fine-tuning).

Mục lục phần

- 1 LoRA - Parameter-Efficient Fine-Tuning - Tinh chỉnh tham số hiệu quả
- 2 **DoRA: : Weight-Decomposed Low-Rank Adaptation**
 - Nền tảng toán học - Weight Normalization
 - Kiến trúc toán học của DoRA
 - **Phân tích Gradient của DoRA**
 - Đột phá hình học - Phép chiếu trực giao
 - Phân tích Động học: Tương quan nghịch giữa Hướng và Độ lớn
 - Tối ưu hóa bộ nhớ: Cơ chế Detached Gradient
- 3 Tài liệu tham khảo

Gradient của DoRA

Xét quá trình lan truyền ngược qua phân rã trọng số $W = m \frac{V}{\|V\|_c}$. Theo quy tắc dây chuyền, gradient đối với thành phần hướng $V' = V + \Delta V$ và độ lớn m là:

$$\nabla_{V'} \mathcal{L} = \frac{m}{\|V\|_c} \left(I - \frac{V' V'^T}{\|V'\|_c^2} \right) \nabla_{W'} \mathcal{L} \quad (1)$$

$$\nabla_m \mathcal{L} = \frac{\nabla_{W'} \mathcal{L} \cdot V'}{\|V'\|_c} \quad (2)$$

Mục lục phần

- 1 LoRA - Parameter-Efficient Fine-Tuning - Tinh chỉnh tham số hiệu quả
- 2 **DoRA: : Weight-Decomposed Low-Rank Adaptation**
 - Nền tảng toán học - Weight Normalization
 - Kiến trúc toán học của DoRA
 - Phân tích Gradient của DoRA
 - **Đột phá hình học - Phép chiếu trực giao**
 - Phân tích Động học: Tương quan nghịch giữa Hướng và Độ lớn
 - Tối ưu hóa bộ nhớ: Cơ chế Detached Gradient
- 3 Tài liệu tham khảo

Đột phá hình học - Phép chiếu trực giao

- Từ phương trình (1), ta có thể định nghĩa toán tử chiếu trực giao P :

$$P = I - \frac{V'V'^T}{\|V'\|_c^2}$$

- Toán tử này loại bỏ hoàn toàn thành phần xuyên tâm vì:

$$PV' = V' - \frac{V'(V'^TV')}{\|V'\|_c^2} = V' - V' = 0$$

- Suy ra, gradient đối với thành phần hướng $\nabla_{V'}\mathcal{L} \propto P\nabla_{W'}\mathcal{L}$ luôn nằm trong không gian tiếp tuyến trực giao với V' :

$$V'^T\nabla_{V'}\mathcal{L} = 0$$

- **Ý nghĩa hình học:** Nhờ vào tính trực giao, DoRA thiết lập một cơ chế tách biệt hoàn toàn: việc xoay hướng trọng số không còn làm biến động độ lớn, và ngược lại, việc điều chỉnh độ lớn không làm sai lệch hướng. Sự độc lập này cho phép mô hình tối ưu hóa từng thành phần một cách tinh tế, loại bỏ sự ràng buộc gây nhiều vốn là điểm yếu cố hữu của LoRA chuẩn.

Mục lục phần

- 1 LoRA - Parameter-Efficient Fine-Tuning - Tinh chỉnh tham số hiệu quả
- 2 **DoRA: : Weight-Decomposed Low-Rank Adaptation**
 - Nền tảng toán học - Weight Normalization
 - Kiến trúc toán học của DoRA
 - Phân tích Gradient của DoRA
 - Động phá hình học - Phép chiếu trực giao
 - **Phân tích Động học: Tương quan nghịch giữa Hướng và Độ lớn**
 - Tối ưu hóa bộ nhớ: Cơ chế Detached Gradient
- 3 Tài liệu tham khảo

Phân tích Động học (I)

Ở đây, ta sử dụng các kí hiệu chữ cái viết thường cho vector thay vì các kí hiệu ma trận như các slide trước. Việc chuyển sang ký hiệu vector chữ thường nhằm phân tích hành vi hình học độc lập của từng cột trọng số (tương ứng với mỗi neuron), giúp đơn giản hóa việc chứng minh các thuộc tính về hướng và độ lớn.

Xét cập nhật tham số cho các trọng số: $w'' = w' + \Delta w$ với $\Delta w \propto \nabla_{w'} \mathcal{L}$.

Giả thuyết so sánh: Xét hai kịch bản cập nhật S_1 và S_2 , với $\Delta D_{S_1} < \Delta D_{S_2}$ (kịch bản S_1 có bước nhảy về hướng nhỏ hơn).

Giả sử $\|\Delta w_{S_1}\| = \|\Delta w_{S_2}\|$, và tại thời điểm ban đầu, ta có $\Delta v = 0$ và $v' = v$.

Từ điều kiện $\Delta D_{S_1} < \Delta D_{S_2}$, ta có $|\cos(\Delta w_{S_1}, w')| > |\cos(\Delta w_{S_2}, w')|$.

Vì $\Delta w \propto \nabla_{w'} \mathcal{L}$, ta có $\left| \cos\left(\nabla_{w'}^{S_1} \mathcal{L}, w'\right) \right| > \left| \cos\left(\nabla_{w'}^{S_2} \mathcal{L}, w'\right) \right|$.

Với việc khởi tạo $v = v_0$ và $w' = w_0$ tại thời điểm ban đầu, ta có thể thay thế w' bằng v trong biểu thức cosine, dẫn đến $|\cos(\nabla_{w'} \mathcal{L}, w')| = |\cos(\nabla_{w'} \mathcal{L}, v')| = |\cos(\nabla_{w'} \mathcal{L}, v)|$.

Với $\Delta v = 0$, ta có

$$|\cos(\nabla_{w'} \mathcal{L}, w')| = |\cos(\nabla_{w'} \mathcal{L}, v')| = |\cos(\nabla_{w'} \mathcal{L}, v)| = \frac{\nabla_{w'} \mathcal{L} \cdot v}{\|\nabla_{w'} \mathcal{L}\| \|v\|}.$$

Phân tích Động học (II)

Gọi m_* là tham số độ lớn của vector w' , khi đó phương trình (2) có thể viết lại thành:

$$\nabla_{m_*} \mathcal{L} = \frac{\nabla_{w'} \mathcal{L} \cdot v'}{\|v'\|_c} = \|\nabla_{w'} \mathcal{L}\| \cdot \cos(\nabla_{w'} \mathcal{L}, v)$$

Bởi $\|\Delta w_{S_1}\| = \|\Delta w_{S_2}\|$, ta có $\|\nabla_{w'}^{S_1} \mathcal{L}\| = \|\nabla_{w'}^{S_2} \mathcal{L}\|$. Do đó, với $|\cos(\nabla_{w'}^{S_1} \mathcal{L}, v)| > |\cos(\nabla_{w'}^{S_2} \mathcal{L}, v)|$, ta có

$$|\nabla_{m_*}^{S_1} \mathcal{L}| > |\nabla_{m_*}^{S_2} \mathcal{L}|.$$

- **Hệ quả trực tiếp:**

$$\Delta D_{S_1} < \Delta D_{S_2} \implies |\nabla_{m_*}^{S_1} \mathcal{L}| > |\nabla_{m_*}^{S_2} \mathcal{L}|$$

- **Phân tích kết quả:**

- S_1 : Thay đổi hướng **ít** $\implies$ Cập nhật độ lớn **nhiều**.
- S_2 : Thay đổi hướng **nhiều** $\implies$ Cập nhật độ lớn **ít**.

Kết luận: Sự tự điều tiết của DoRA

DoRA thiết lập mối tương quan nghịch giữa hướng và độ lớn. Khi mô hình cần thay đổi đặc trưng mạnh mẽ (xoay hướng), nó sẽ tự động giảm sự biến động về cường độ (độ lớn).

Mục lục phần

- 1 LoRA - Parameter-Efficient Fine-Tuning - Tinh chỉnh tham số hiệu quả
- 2 **DoRA: : Weight-Decomposed Low-Rank Adaptation**
 - Nền tảng toán học - Weight Normalization
 - Kiến trúc toán học của DoRA
 - Phân tích Gradient của DoRA
 - Đột phá hình học - Phép chiếu trực giao
 - Phân tích Động học: Tương quan nghịch giữa Hướng và Độ lớn
 - **Tối ưu hóa bộ nhớ: Cơ chế Detached Gradient**
- 3 Tài liệu tham khảo

Tối ưu hóa bộ nhớ: Cơ chế Detached Gradient

Vấn đề: Chi phí bộ nhớ (VRAM)

- Gradient nhánh hướng (1) khác biệt so với W' , buộc đồ thị tính toán lưu nhiều biến trung gian.
- Gây tăng mức tiêu thụ VRAM đáng kể trong Backpropagation.

Nhóm nghiên cứu đã đề xuất giải pháp để khắc phục vấn đề này mà không làm mất đi tính hiệu quả của DoRA.

Giải pháp: Detaching $\|V'\|_c$

- Coi $\|V + \Delta V\|_c$ là **hằng số** khi tính đạo hàm.
- **Forward:** Cập nhật giá trị động.
- **Backward:** Ngắt khỏi đồ thị gradient (không truyền đạo hàm qua chuẩn c).

Công thức rút gọn:

$$\nabla_{V'} \mathcal{L} = \frac{m}{C} \nabla_{W'} \mathcal{L}$$

với $C = \|V'\|_c$ (*detached*)

Kết luận

Cơ chế này đưa chi phí bộ nhớ của DoRA nhỏ hơn nhưng vẫn giữ được ưu thế hội tụ của Full Fine-tuning.

Mã giả – DoRA Forward

Thuật toán merged_weight

- ➊ $\Delta \leftarrow BA \times \frac{\alpha}{r}$
- ➋ $V \leftarrow W_0 + \Delta$
- ➌ $\mathbf{n} \leftarrow \|V\|_c$ (chuẩn cột)
- ➍ **Nếu detach:** $\mathbf{n} \leftarrow \mathbf{n}.\text{detach}()$
- ➎ $\mathbf{n} \leftarrow \max(\mathbf{n}, \varepsilon)$
- ➏ **Trả về** $m \odot V \oslash \mathbf{n}$ (nhân/chia theo cột)

Thuật toán forward

- ➊ **Nếu merged:**
 - Trả về $\text{Linear}(x, W_0, b)$
- ➋ **Nếu không bật adapter:**
 - Trả về $\text{Linear}(x, W_0, b)$
- ➌ $W' \leftarrow \text{merged_weight}()$
- ➍ Trả về $\text{Linear}(x, W', b)$

Mã giả – apply_peft & Quản lý Adapter

Hàm apply_peft

- ❶ Với mỗi module_name, module trong model:
 - ❶ Nếu tên khớp với target_modules và module là Linear:
 - Tạo LoRALinear hoặc DoRALinear
 - Thay thế module cha
- ❷ Trả về danh sách tên module đã thay thế

Lưu / Tải adapter

- ❶ Lưu:
 - ❶ Thu thập các tham số huấn luyện được (lora_A, lora_B, magnitude,...)
 - ❷ Lưu vào file với tên module tương ứng
- ❷ Tải:
 - ❶ Đọc file đã lưu
 - ❷ Với mỗi module trong file:
 - Sao chép tham số vào module tương ứng trong model hiện tại

Mục lục phần

- 1 LoRA - Parameter-Efficient Fine-Tuning - Tinh chỉnh tham số hiệu quả
- 2 DoRA: : Weight-Decomposed Low-Rank Adaptation
- 3 Tài liệu tham khảo**

Tài liệu tham khảo I



Shih-Yang Liu, et al.

DoRA: Weight-Decomposed Low-Rank Adaptation.

arXiv preprint arXiv:2402.09353, 2024.



Edward J. Hu, et al.

LoRA: Low-Rank Adaptation of Large Language Models.

ICLR, 2022.



Tim Salimans and Diederik P. Kingma.

Weight Normalization: A Simple Reparameterization to Accelerate Training of Deep Neural Networks.

Advances in Neural Information Processing Systems, 2016.

TRÂN TRỌNG CẢM ƠN!

PHẦN THẢO LUẬN (Q&A)